

LBE-LF Vs. SAR-EM

LBE-LF

1. 常数标注概率 η 的情况:

- 如果 η 是常数并且与 x 无关, 则 $\eta = P(s = 1|y = 1)$, 可以直接通过数据估计出来。公式为:

$$\eta = \frac{P(s = 1, y = 1)}{P(y = 1)} = \frac{P(s = 1)}{P(y = 1)}$$

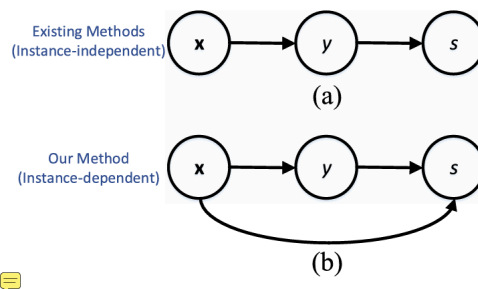
- 其中 $P(s = 1)$ 和 $P(y = 1)$ 可以直接从数据中估计。

2. 实例相关标注概率 $\eta(x)$ 的情况:

- 当 η 是与 x 相关的函数 $\eta(x)$ 时, 情况变得复杂。在这种情况下, 我们有:

$$\eta(x) = P(s = 1|y = 1, x) = \frac{P(s = 1, y = 1|x)}{P(y = 1|x)} = \frac{P(s = 1|x)}{P(y = 1|x)}$$

- 这表明 $\eta(x)$ 和类后验概率 $P(y = 1|x)$ 是共存的。因此, 为了估计 $\eta(x)$ 和 $P(y = 1|x)$, 需要找到一种新的方法来联合估计这两个概率。



由图(b)得到:

$$P(y, s|x) = P(y|x)P(s|y, x)$$

带入PU数据集后得到:

$$P(y, s|x) = \prod_{i=1}^n P(y_i, s_i|x_i) = \prod_{i=1}^n P(y_i|x_i)P(s_i|y_i, x_i)$$

构造分类器:

$$h(x; \theta_1) = P(y = 1|x) = (1 + \exp(-\theta_1^\top x))^{-1}$$

$$\eta(x; \theta_2) = P(s = 1|y = 1, x) = (1 + \exp(-\theta_2^\top x))^{-1}$$

最大化似然函数：

$$\arg \max_{\theta} \prod_{i=1}^n \sum_{y_i} P(s_i, y_i | x_i; \theta).$$

对数似然：

$$\arg \max_{\theta} \mathcal{L}(\theta) = \sum_{i=1}^n \log \sum_{y_i} P(s_i, y_i | x_i; \theta).$$

因为存在未知变量 y_i ，通过EM算法求解。

LBE-LF E步

在E步中，希望计算每个数据点 i 的潜在变量 y_i 的后验概率

$\tilde{P}(y_i) = P(y_i | x_i, s_i)$ 。这是因为我们无法直接观测到 y_i ，但可以通过观测到的变量 x_i 和 s_i 来推断 y_i 的概率。

联合概率的分解

根据条件独立性和贝叶斯定理，我们可以将联合概率 $P(y_i, s_i | x_i)$ 分解为：

$$P(y_i, s_i | x_i) = P(s_i | x_i) P(y_i | x_i, s_i)$$

这里我们主要关注 $\tilde{P}(y_i)$ ，即 $P(y_i | x_i, s_i)$ 。

通过贝叶斯定理，将 $P(y_i | x_i, s_i)$ 表示为：

$$P(y_i | x_i, s_i) = \frac{P(s_i | y_i, x_i) P(y_i | x_i)}{P(s_i | x_i)}$$

计算 $P(s_i | x_i)$ 是不必要的，因为它只是一个归一化常数。

使用比例表示法：

$$P(y_i | x_i, s_i) \propto P(s_i | y_i, x_i) P(y_i | x_i)$$

即：

$$\tilde{P}(y_i) = P(y_i | x_i, s_i) \propto P(s_i | y_i, x_i) P(y_i | x_i)$$

其中：

- $P(s_i | y_i, x_i)$ ：表示给定 y_i 和 x_i 后，观察到 s_i 的概率。通过 $\eta(x)$ 得到。
- $P(y_i | x_i)$ ：表示给定 x_i 后， y_i 的先验概率。通过 $h(x)$ 得到。

LBE-LF M步

期望对数似然函数的定义如下：

$$\mathcal{J}(\theta) = \sum_i \mathbb{E}_{\hat{P}(y_i)} [\log P(y_i, s_i | x_i; \theta)]$$

这个函数表示的是在E步计算出的隐变量 y_i 的期望值基础上，对参数 θ 的期望对数似然。

在M步中，我们的目标是最大化 $\mathcal{J}(\theta)$ ，即：

$$\max_{\theta} \mathcal{J}(\theta)$$

将期望对数似然函数 $\mathcal{J}(\theta)$ 展开，可以得到：

$$\mathcal{J}(\theta) = \sum_i \mathbb{E}_{\hat{P}(y_i)} [\log P(y_i | x_i; \theta_1) + \log P(s_i | y_i, x_i; \theta_2)]$$

对 θ_1 的梯度

梯度 $\nabla_{\theta_1} \mathcal{J}(\theta)$ ：

$$\nabla_{\theta_1} \mathcal{J}(\theta) = \sum_i \nabla_{\theta_1} \mathbb{E}_{\hat{P}(y_i)} [\log P(y_i | x_i; \theta_1)]$$

展开并化简得到：

$$\nabla_{\theta_1} \mathcal{J}(\theta) = \sum_i \sum_{y_i} \hat{P}(y_i) \nabla_{\theta_1} \log P(y_i | x_i; \theta_1)$$

进一步化简：

$$\nabla_{\theta_1} \mathcal{J}(\theta) = \sum_i \hat{P}(y_i = 1) \nabla_{\theta_1} \log P(y_i = 1 | x_i; \theta_1) + \hat{P}(y_i = 0) \nabla_{\theta_1} \log P(y_i = 0 | x_i; \theta_1)$$

对 θ_2 的梯度

梯度 $\nabla_{\theta_2} \mathcal{J}(\theta)$ ：

$$\nabla_{\theta_2} \mathcal{J}(\theta) = \sum_i \nabla_{\theta_2} \mathbb{E}_{\hat{P}(y_i)} [\log P(s_i | y_i, x_i; \theta_2)]$$

展开并化简得到：

$$\nabla_{\theta_2} \mathcal{J}(\theta) = \sum_i \sum_{y_i} \hat{P}(y_i) \nabla_{\theta_2} \log P(s_i | y_i, x_i; \theta_2)$$

进一步化简：

$$\nabla_{\theta_2} \mathcal{J}(\theta) = \sum_i \hat{P}(y_i = 1) \nabla_{\theta_2} \log P(s_i | y_i = 1, x_i; \theta_2) + \hat{P}(y_i = 0) \nabla_{\theta_2} \log P(s_i | y_i = 0, x_i; \theta_2)$$

对于LBE-LF来说，

使用Adam优化器进行梯度更新，具体步骤如下：

1. 计算梯度 $\nabla_{\theta_1} \mathcal{J}(\theta)$ 和 $\nabla_{\theta_2} \mathcal{J}(\theta)$ 。
2. 使用Adam优化器根据计算出的梯度更新参数。

SAR-EM

•